

Relatório do Trabalho 3 de Ciência dos Dados

EQUIPE:

Gustavo Campelo de Sousa – 511817

Pablo Kauan Martins Timbó – 556012

Rodolfo Rodrigues de Araújo – 508473

Lucas Evangelista de Carvalho - 510158

Regressão

DATASET: <https://www.kaggle.com/datasets/quantbruce/real-estate-price-prediction>

Neste trabalho foi analisado um dataset disponibilizado na plataforma Kaggle com o objetivo de estimar o preço da unidade de área de imóveis. Inicialmente, realizou-se uma análise exploratória dos dados, incluindo a plotagem de gráficos das principais features ao longo do tempo, boxplots para identificação de dispersão e possíveis outliers, além de uma visualização em 3D considerando latitude, longitude e preço, permitindo uma melhor compreensão da distribuição espacial dos valores imobiliários.

Na etapa de pré-processamento, aplicou-se One Hot Encoding às variáveis categóricas. Algumas variáveis contínuas foram transformadas em intervalos, visando capturar padrões não lineares, e o StandardScaler foi utilizado para padronização de determinadas features, garantindo melhor desempenho dos modelos sensíveis à escala dos dados.

Foram treinados e avaliados diferentes modelos de regressão: Regressão Linear, Árvore de Decisão, Random Forest e XGBoost. A Regressão Linear apresentou desempenho razoável, com $R^2 = 0,736$, indicando capacidade limitada de capturar relações mais complexas. Já os modelos baseados em árvores obtiveram melhores resultados, destacando-se a Árvore de Decisão e o Random Forest, ambos com $R^2 = 0,797$ e menores valores de RMSE e MAE no conjunto de teste. O modelo XGBoost apresentou desempenho intermediário, com $R^2 = 0,755$.

De forma geral, os resultados indicam que modelos ensemble baseados em árvores são mais adequados para o problema proposto, por conseguirem capturar melhor as relações não lineares presentes nos dados imobiliários, oferecendo maior precisão na estimativa do preço da unidade de área dos imóveis.

Classificação

DATASET: <https://www.kaggle.com/datasets/quantbruce/real-estate-price-prediction>

No trabalho foi analisado um dataset disponibilizado na plataforma Kaggle com o objetivo de estimar o score do exame de um aluno a partir de seus dados relacionados aos hábitos e condições de estudo. Inicialmente, realizou-se uma análise exploratória das features por meio de tabelas contendo valores mínimos e máximos, permitindo compreender a distribuição e a amplitude das variáveis do conjunto de dados e a padronização da variável

objetivo que antes contava com o valor do score e transformamos para true as que eram acima de 60.

Na etapa de pré-processamento, aplicou-se One Hot Encoding às variáveis categóricas nominais, enquanto as variáveis categóricas ordinais foram transformadas por meio de Label Encoding manual, respeitando sua hierarquia natural. Também foi realizada a verificação de dados faltantes, assegurando a consistência do dataset antes da etapa de modelagem.

Foram treinados e avaliados diferentes modelos de classificação, incluindo Regressão Logística, SVM, XGBoost, Random Forest, Naive Bayes e k-NN. A avaliação foi conduzida com base nas métricas Accuracy, Precision, Recall, F1-score e ROC-AUC. Os resultados indicaram que a Regressão Logística apresentou o melhor desempenho geral, alcançando acurácia de 0,842 e ROC-AUC de 0,925, seguida de perto pelo modelo SVM. Os modelos baseados em ensemble e métodos probabilísticos apresentaram desempenho competitivo, porém inferior aos dois primeiros, enquanto o k-NN obteve os menores valores nas métricas avaliadas.

De modo geral, os resultados demonstram que modelos lineares bem ajustados podem ser altamente eficazes para este tipo de problema, especialmente quando acompanhados de um pré-processamento adequado e uma boa representação das variáveis categóricas.

Processamento de Linguagem Natural

DATASET: <https://www.kaggle.com/datasets/marlesson/news-of-the-site-folhauol>


Neste trabalho utilizou-se um dataset disponibilizado na plataforma Kaggle, este que contém 167.053 notícias em português do Brasil. Ele possui 6 colunas: título da notícia, texto da notícia, data de publicação, categoria, subcategoria e o link de acesso à notícia. A aplicação das técnicas de processamento de linguagem natural teve o intuito de prever a categoria da notícia, caracterizando um problema de classificação supervisionada do texto ao explorar diferentes representações textuais e algoritmos de aprendizado de máquina.

Na etapa de pré-processamento, foram realizados os procedimentos padrões, como a verificação de valores nulos, onde as únicas colunas com valores nulos foram a de text com 765 e a de subcategory com 137418. Feito isso, os valores foram tratados com o preenchimento de string vazia. Neste momento, ao visualizar a quantidade de 48 categorias, a distribuição não estava balanceada, então optou-se por utilizar apenas as 7 categorias mais abrangentes, que foram as de poder com 22022 aparições, colunas com 21622, mercado com 20970, esporte com 19730, mundo com 17130, cotidiano com 16967 e ilustrada com 16345; a título de comparação, a categoria seguinte com mais aparições continha apenas 4525, e algumas possuíam apenas 1, então optou-se por manter apenas as 7 mais presentes. Assim, filtrado o dataset, sem valores nulos em todas as colunas, mais por questão de formalidade, visto que nem todas as colunas seriam utilizadas, **unificou-se** as colunas de title + text, pois dessa forma teríamos um contexto maior e melhor chance de acerto nas predições ao unir a manchete da notícia ao seu corpo. Por último, nessa fase de

pré-processamento, foi normalizado o texto com lowercase, remoção de urls, números, pontuação básica e múltiplos espaços.

A próxima etapa foi a de preparação para a aplicação do Bag of Words e TF-IDF. Primeiro, dividimos o conjunto em treino e teste, com 80% para treino e 20% para teste, com `random_state` no valor de 42 e aplicando a estratificação. Aplicou-se primeiro o Bag of Words, onde vetorizamos com os hiperparâmetros: utilizamos unigramas, `min_df` de valor 5 e `max_df` de valor 0.9. Foi criada uma função de treino e avaliação, onde ao executá-la, teríamos a realização da predição e os resultados das métricas avaliadas, que foram: acurácia, precisão, recall e F1 Score. Com isso, escolhemos 5 modelos para executar a função de treino e avaliação: Naive Bayes, Logistic Regression, SVM, Random Forest e KNN.

O TF-IDF teve processamento parecido, com a diferença da adição de que foi utilizado bigramas, o `max_df` foi de valor 0.8 e utilizamos o `sublinear_tf`. O restante do processo foi idêntico. Ao final do treinamento e predição dos dois métodos, foi feita uma tabela comparativa dos resultados que pode ser visualizada no notebook. O modelo que apresentou melhor métrica foi o **TF-IDF** com o modelo **SVM**, que obteve **acurácia de 0.9362**, **precisão de 0.9364**, **recall de 0.9381** e **F1-Score de 0.9371**, o que significa que a predição das categorias de notícias utilizando o TF-IDF com o SVM foi a abordagem mais eficaz para a tarefa de classificação automática de notícias neste estudo. A matriz de confusão abaixo mostra a corretude das classificações utilizando o melhor modelo.



De certa forma, foi necessária uma curva de aprendizado grande para entender alguns conceitos pouco vistos, e se vistos, não foram estudados profundamente, como as convenções de divisão de conjunto de treino e teste, os hiperparâmetros e o que significava cada um deles, além do que cada função fazia, esses acabaram sendo aprendizados valiosos e muito interessantes. Com relação às dificuldades, é possível citar que os aprendizados casaram bem com as dificuldades, pois uma das maiores foi entender o que as funções de fit e transform faziam, e como o treinamento e a predição funcionam, e sem contar o fator do tempo que os algoritmos levaram para rodar, onde se suspeitava, inicialmente que havia alguma coisa errada, porém em virtude do tamanho do dataset e do poder de processamento da máquina local, foi admitido que uma hora terminaria. A etapa com Bag of Words levou pouco mais de 1 hora e meia, e o TF-IDF quase 1 hora.